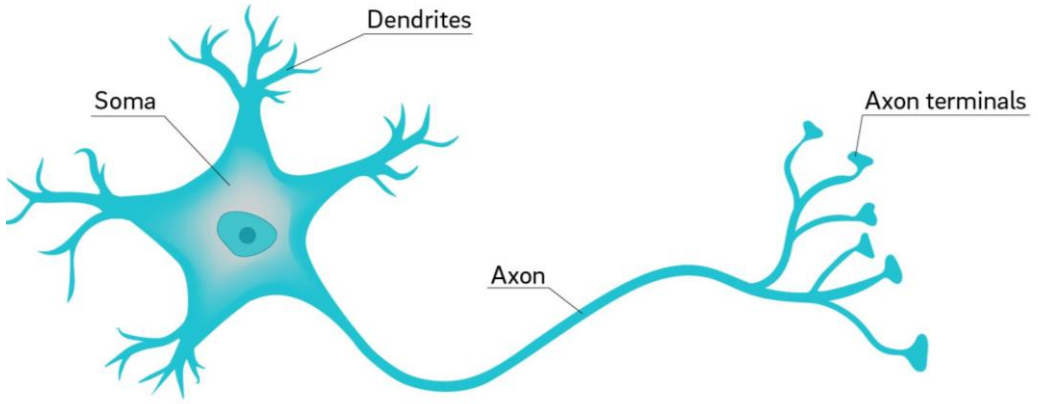
Sisteme inteligente
#10

Sisteme inteligente de tip conexionist. Conceptul de neuron artificial şi funcţionarea lui ca procesor de semnale/date. Neuronul adaptiv liniar (2ore)

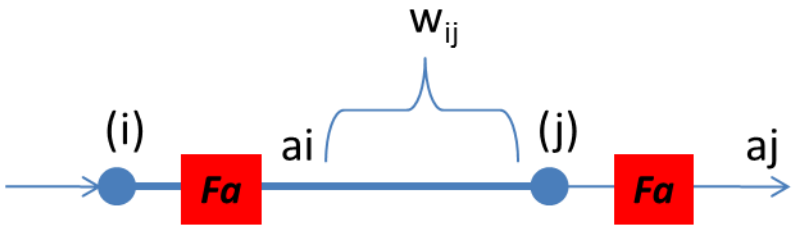
Sisteme inteligente de tip conexionist

- Sunt modele *bioinspirate* care reproduc *structura funcțională a creierului*.
- Se bazează pe o mulțime de *entități de prelucrare* a semnalelor/datelor interconectate între ele, alcătuind *rețele neuronale artificiale*.
- Neuron artificial=model al neuronului biologic. Rețele neuronale artificiale (RNA).
- Funcția: *învățarea*.
- Direcții de dezvoltare: învățarea automată, *machine learning.*



Referinte cronologice in dezvoltarea sistemelor neuronale artificiale

Anul	Autorii	Contribuţii
1943	McCulloch şi Pitts	*Modelul formal* al neuronului elementar. Nu s-a implementat la vremea respectiva din motive tehnologice
1949	Donald Hebb (prima contribuţie la teoria reţelelor neuronale)	*Regula de învăţare hebiana* - prima schemă de învăţare prin *actualizarea conexiunilor neuronului*. S-a stabilit ca informaţia este stocată în conexiuni şi a postulat tehnica invaţării, care a avut un impact profund în dezvoltarea ulterioară a domeniului.



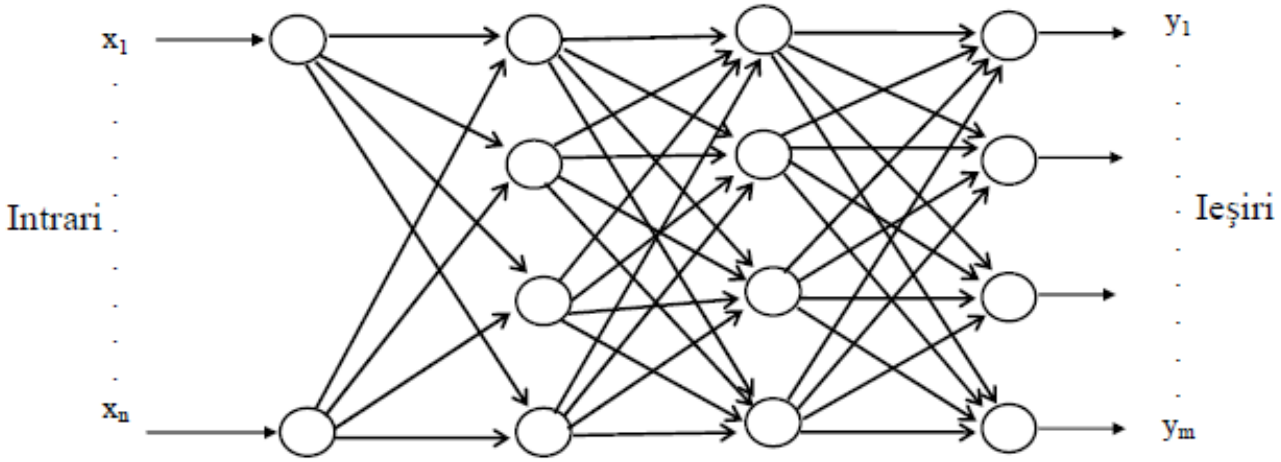
Hebb:

$$\Delta w_{ij} = \eta \cdot ai \cdot aj$$

(1) Conexiuni *intarite*
(2) Conexiuni *inhibate*

Anii ‘50

Anii '50	Minsky ,1954	Construirea şi testarea primelor *neurocomputere*. Acestea sunt capabile să *adapteze automat conexiunile*.
	Frank Rosenblatt, 1958	Inventarea *perceptronului*. Acesta este un **sistem instruibil**, capabil să înveţe să clasifice forme concrete prin modificarea conexiunilor la elementele de intrare. Aceasta idee s-a impus, constituind metoda de bază, utilizată şi astăzi, în cadrul algoritmilor de învăţare a maşinilor.



Anii ‘60

Anii '60	Bernard Widrow şi Marcian Hoff, 1960-1962	Apare dispozitivul cunoscut ca ADALINE (for ADAptive LINEar combiner), acesta consacrand de fapt o nouă metodă de învăţare numita regula de învăţare Widrow-Hoff. Regula are particularitatea că minimizează suma erorilor pătratice pe timpul antrenării reţelei în procesul de clasificare a formelor. Extensia MADALINE (for Many ADALINES) include o serie de aplicaţii pentru **recunoaşterea formelor**, previziunea vremii, controlul adaptiv.
	Nils Nilson, 1965	Prima monografie despre învăţarea maşinilor, prezentand o sinteză a realizărilor şi *formularea limitelor inerente* ale procesului de invăţare a maşinilor prin modificarea conexiunilor. *Insuficienţa teoremelor de existenţă a maşinilor instruibile cu modele neuronale de tip layered networks*, in găsirea unor scheme eficiente de învăţare. Se manifesta *primul impas serios* în dezvoltarea reţelelor neuronale. Cercetările în acest domeniu intră într-o fază de stagnare şi datorită insuficienţei mijloacelor de calcul din epoca respectivă.
	Marvin Minsky şi Seymour Papert, 1969	Se publică lucrarea în care se arată **limitele privind capacitatea de învăţare de tip layered learning**, statuând astfel insuficienţa clasei de reţele de tip perceptron. Problematica va fi rezolvată abia în anii '80.

Anii ’70: periodă de latență în domeniul RNA și preocupări sporadice

Anii '70 constituie perioada de latenţă în domeniul reţelelor neuronale, fiind marcaţi de preocupări sporadice ale unor autori.	Sun -Ichi Amari, 1972,1977	Studiul învăţării în reţele neuronale, elemente de prag, teoria matematică a RN.
	Kunihito Fucushima	Dezvoltă o clasă de arhitecturi neuronale denumite **cognitron şi neocognitron** (Fucushima şi Miyaka, 1980)
	Tuevo Kohonen şi James Anderson, 1977	Cercetări cu privire *la memoria asociativă*
	Stephen Grossberg şi Gail Carpenter, 1974	Introduc o serie de *arhitecturi neuronale* şi formulează concepte dezvoltînd teoria **reţelelor adaptive rezonante. (ART)**

Anii ‘80: relansarea cercetărilor pe baza acumulărilor tehnologice și pe dezvoltarea unor teorii anterioare

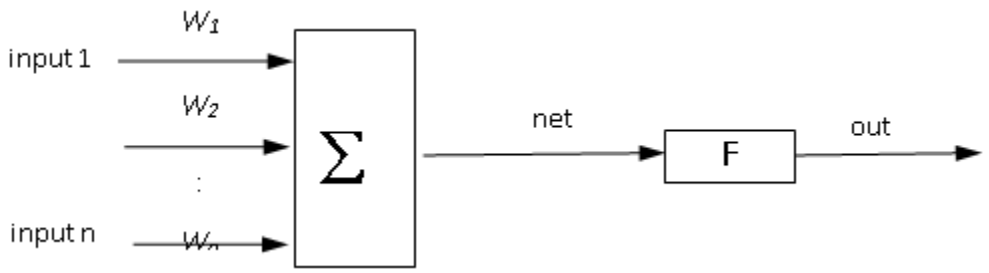
Anii '80 marchează renaşterea cercetărilor în domeniul RNA, bazată pe acumulările tehnologice dar şi pe dezvoltarea unor teorii anterioare.	John Hopfield, 1982,1984	Relansează cercetările in domeniu prin introducerea arhitecturii de **reţea neuronală recurentă** pentru memoriile asociative. Formulează proprietăţile de calcul ale unei reţele cu elemente total conectate.
	Kohonen, 1982	Reţelele cu **învăţare nesupervizată**.
	James McClelland şi David Rumelhart, 1986	Apare lucrarea de referinţă despre *procesarea paralelă distribuită*. Începand cu anul 1986 apar programe de cercetare în domeniul RNA. Se conturează noua disciplină- *neurocomputing*. Apar numeroase aplicaţii practice cu sisteme neuronale. Apar implementări hardware integrate.

Prezent

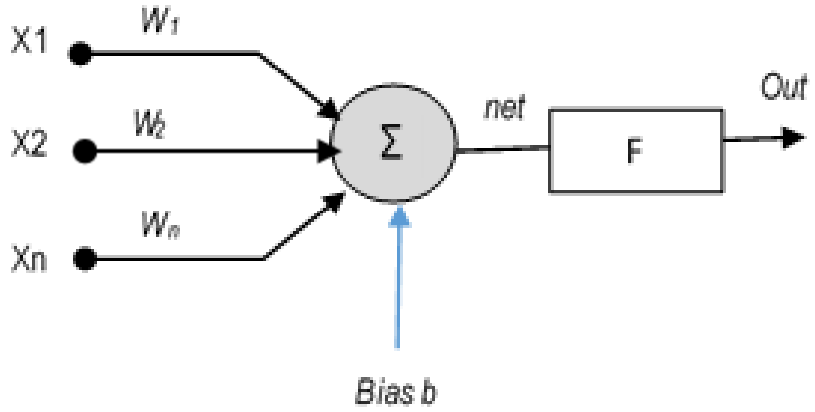
- Machine learning.
- Rețele neuronale convoluționale – ‘*deep learning*’.
- Structuri neuromorfice implementate hardware (FPGA).
- Apariția *memristorului*.
- Proiectul Blue Brain.

Neuronul artificial

- **Reţelele neuronale artificiale (RNA)** au ca punct de inspiraţie structura sistemului nervos al fiinţelor. Studiul acestora a apărut o datã cu primele noţiuni de I.A. în încercarea de a reproduce în sistemele artificiale procese mentale superioare (vorbirea, raţionarea) recunoaşterea scenelor sau procese psiho-motorii bazate pe reflexe necondiţionate şi/sau condiţionate (mersul, înotul, condusul unui autovehicul etc.).
- **Unitatea de bazã a sistemului nervos este neuronul** care poate fi modelat din punct de vedere al proceselor biofizice, dupã mai multe teorii. ***Neuronul artificial*** *este o copie mult simplificatã a originalului biologic*. Asemănarea este mai mare în ceea ce priveşte structura funcţională de principiu şi mai puţin adevăratã în ceea ce priveşte procesele fizice care au loc.
- În principiu, un neuron îndeplineşte două funcţii majore:
  - *comunicarea* (transmiterea) informaţiei;
  - *prelucrarea* locală a informaţiei.
- Astfel **un neuron artificial** este un **procesor elementar** fiind organizat după arhitectura unui sistem MISO (Multiple Input/Single Output) cu *n* circuite de intrare (input) caracterizate de ponderile asociate *Wn*, un circuit de însumare (∑), un bloc functional de activare (F) precum şi o ieşire (out). Structura unui astfel de neuron artificial este reprezentată mai jos



Modelul matematic al neuronului



net= $b + \sum_{i=1}^{n} Xi\ Wi$

Out=F(net)

X- intrari
W - ponderi
F – funcție de activare
net – semnal de rețea
b – semnal de bias

Funcții de activare

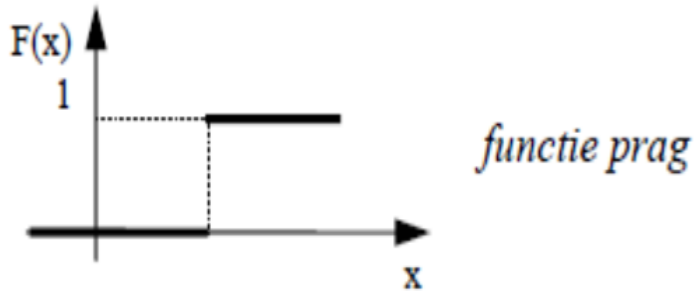
Implementează o funcție a axonului:

Răspunsul neuronului (*Out*) în funcție de valoarea semnalului de rețea (*net*), unde

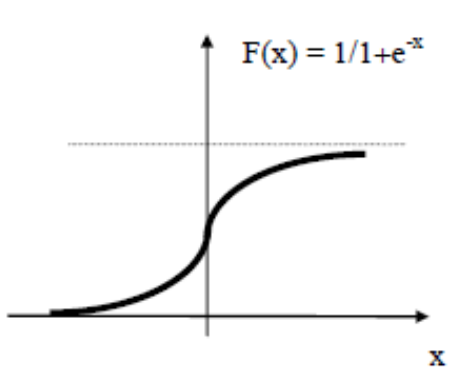
x = valoarea net

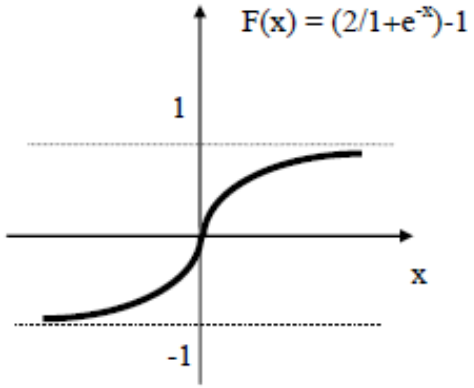
F(x) = Out

$$F(x) = \begin{cases} 1, x \geq t \\ 0, altfel \end{cases}$$



functie prag

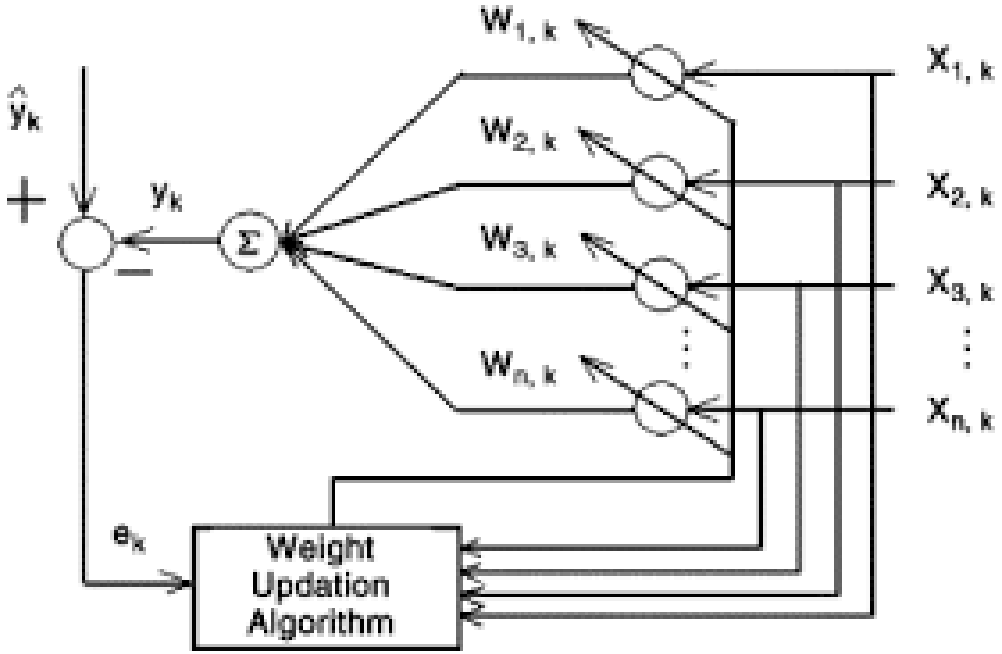


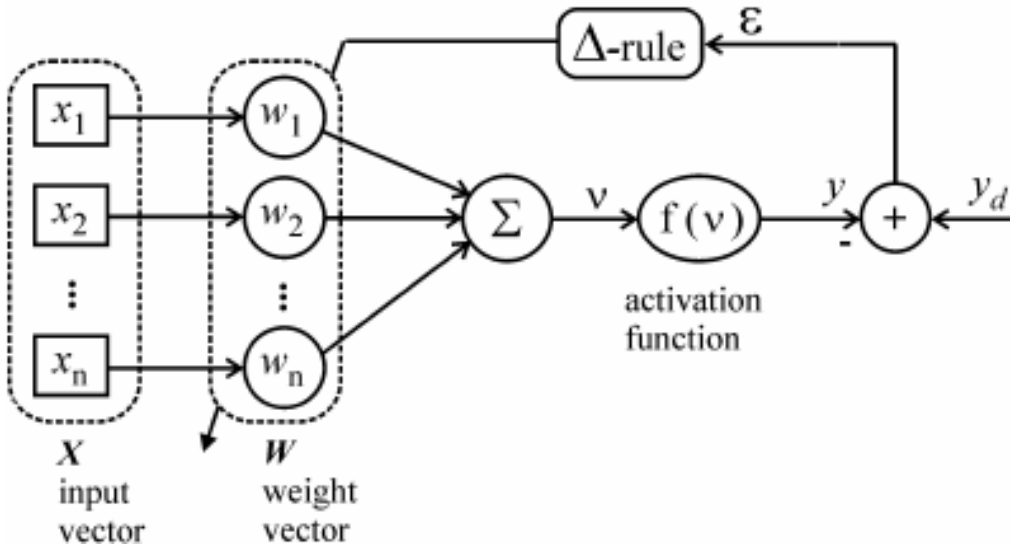


funcție sigmoidală

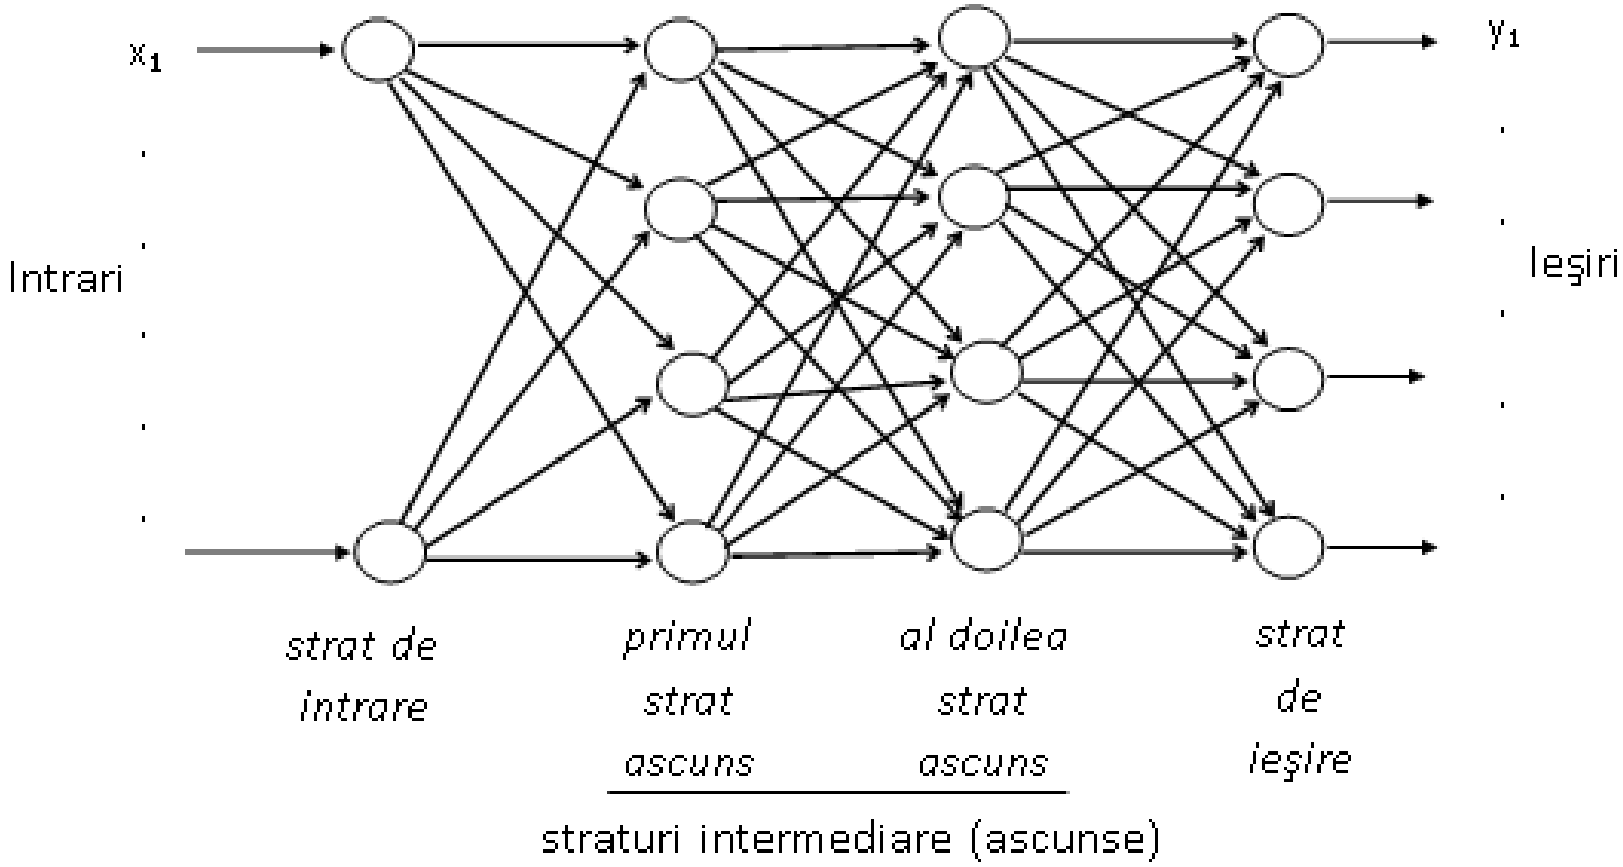
Neuronul ADALINE

- **Ada**ptive **Li**near **Ne**uron
- Regula de învățare originală: *Widrow-Hoff* (depinde de y_d, w_{ij} *și* x_i), ulterior și alte reguli de învățare





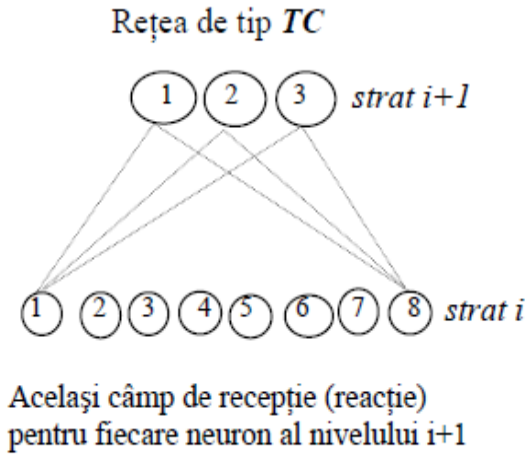
Perceptronul multistrat



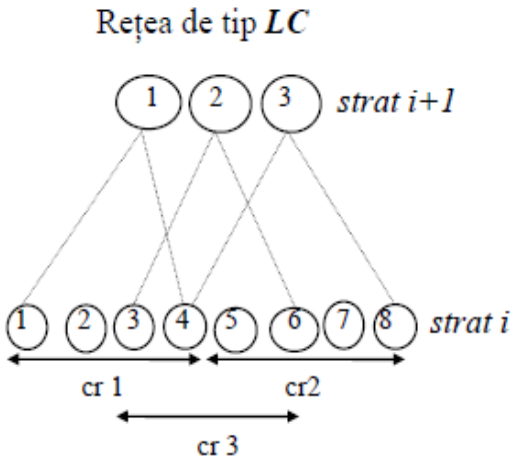
Perceptronul multistrat

- Rețea neuronală de tip *feed-foreward*
- Rețea *total conectată*

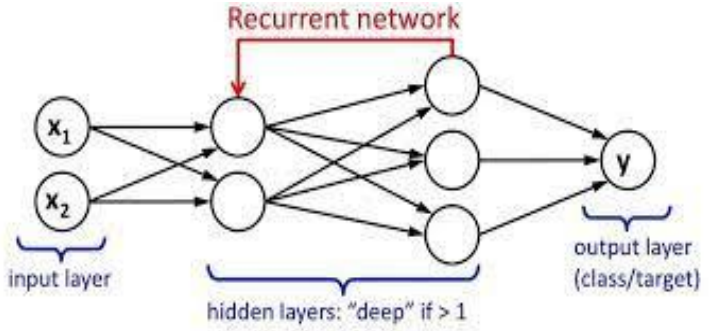
<u>Conectivitatea neuronilor într-o rețea</u>:
- Total conectați (TC) sau local conectați (LC),
- Legături cu propagare exclusiv înainte (feed-foreward) sau și cu propagare înapoi (recurență)

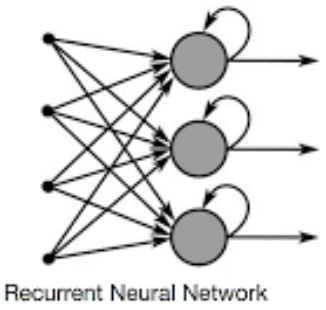


Același câmp de recepție (reacție)
pentru fiecare neuron al nivelului i+1



cr - câmpuri de reacție (nu neapărat disjuncte)





Particularități ale RNA

- Toate aplicaţiile recente sau mai vechi ale reţelelor neuronale artificiale se bazează pe **paradigma conexionistă**, care a introdus *un nou concept de calcul* - *calculul neuronal* - tinzând să reproducă cât mai fidel procesele mentale ale creierului uman, acestea se bazează în primul rând pe funcţia de *memorare* la nivel de reţea.
- **Particularităţile de bază** ale modelelor neuronale în procesul de memorare prin învăţare/antrenare/instruire sunt:
- În RNA informaţia nu mai este memoratã în zone bine precizate (ca în cazul calculatoarelor standard) ci *este memoratã difuz în toatã reţeaua*, pe baza stabilirii valorilor corespunzãtoare ale *ponderilor conexiunilor sinaptice* dintre neuronii reţelei;
- Rezolvarea unei probleme specifice cu modelul conexionist **nu mai necesitã elaborarea unui model logico-formal şi a unui algoritm pentru rezolvarea acestuia** (ca în abordãrile tradiţionale), ci recurge la învăţarea din exemple predefinite - proces numit instruire sau antrenare a reţelelor neuronale (practic RNA îşi construieşte “singură ” algoritmul pentru problema propusã - sintetizând în mod implicit un anumti model al acestuia).

Proprietăți ale RNA

1)Capacitatea de a învăţa

- Fără a utiliza programe puternice, RNA pot fi antrenate pe baza unui set de intrări (şi eventual cu ieşiri dorite) pentru a rezolva problemele pentru care au fost proiectate. Algoritmii de antrenare a reţelelor neuronale se împart în două categorii: ***supervizaţi şi nesupervizaţi***.

a) Învăţarea supervizată - se bazează pe metoda *încercare şi eroare* care se realizează prin algoritmul de propagare înapoi (backpropagation). Această tehnică de antrenare (instruire) a reţelei neuronale presupune pentru fiecare vector de intrare câte un vector de ieşire reprezentând răspunsul care se doreşte să-l ofere reţeaua, când se prezintă la intrare vectorul de intrare. Împreună, cei doi vectori asociaţi formează o pereche de antrenament. Numărul de perechi de antrenament necesare depinde de tipul şi complexitatea problemei.

b) Învăţarea nesupervizată - nu necesită vectori de antrenament şi nici operaţii de compunere şi propagare înapoi a erorilor, în procesul de determinarea a răspunsului ideal (ca în cazul învăţării supervizate). Setul de antrenament constă numai din vectori de intrare, care, pe parcurs sunt grupaţi în clase ce determină aceleaşi ieşiri. Altfel spus, aplicându-se unul din vectorii de intrare sau un vector suficient de apropiat de acesta (din aceeaşi clasă) reţeaua va produce aceeaşi ieşire. Trebuie menţionat că nu există nici o posibilitate de anticipare (înainte de antrenament), a vectorului de ieşire asociat de reţea unei clase din setul vectorilor de antrenament. Tehnica învăţării nesupervizate se apropie mai mult de modul de învăţare într-un sistem biologic.

Proprietăți ale RNA (cont.)

2) Capacitatea de generalizare a RNA.

- O datã antrenatã pentru o anumitã problemã, o reţea neuronalã *este capabilã sã dea* ***rãspunsuri corecte şi pentru intrãri diferite*** de cele cu care a fost antrenatã, dar nu mult diferite de acestea.
- Este important faptul cã RN artificiale *generalizează în mod automat*, ca o consecinţã a structurii lor şi nu cu ajutorul inteligenţei umane implementatã într-un program de calcul.

3) Capacitatea de sintezã.

- Când sunt confruntate cu ***informaţii complexe sau parţiale***, precum cele cu *zgomot* sau *intrãri irelevante*, RN artificiale pot lua decizii sau trage concluzii. *De exemplu, o reţea pentru recunoaşterea caracterelor, antrenatã cu seturi distorsionate ale literei A, va avea ca rezultat la ieşire litera corectă, chiar dacã la intrare i se prezintã versiuni distorsionate ale acesteia*. Deci reţeaua este capabilã să sintetizeze o situaţie cu care nu s-a mai confruntat.

Învățarea supervizată

1) Algoritmul de propagare înapoi (backpropagation)

Acest algoritm este **specific tehnicii de *învãţare supervizatã*** a reţelelor de tip feedforward cu oricâte nivele, dar poate fi aplicat şi reţelelor cu feedback. Algoritmul de propagare înapoi are doi paşi importanţi: **forward şi backward**.

a) **Pasul forward** - *propagarea intrării spre ieşire, nivel cu nivel*.

- se aplicã intrarea din perechea de antrenament la intrarea reţelei (*inp*);
- în prealabil, ponderile reţelei (*Wi*) sunt iniţializate cu valori aleatoare mici;
- se calculează valorile (*net*) pentru fiecare neuron din primul nivel, ca *sume ponderate ale intrãrilor* în neuronul respectiv:

$$netj = \sum_{i=1}^{n} inp_i W_i \quad , \qquad j = \text{nr. neuron}$$

- se aplică funcţia de activare pentru fiecare neuron din primul nivel stabilind ieşirile fiecărui neuron al acestui nivel:

$$outj = F(netj);$$

- ieşirile neuronilor din primul nivel servesc ca intrări în neuronii nivelului imediat următor;
- procesul se repetă nivel cu nivel până se ajunge la nivelul de ieşire şi se determină valorile ieşirii reţelei (output).

Învățarea supervizată (cont.)

b) Pasul backward - ajustarea efectivã a ponderilor reţelei.

Principiul acestei etape se bazează pe:

output - ieşirea calculată a reţelei;

inp - intrarea reţelei;

W - setul ponderilor reţelei;

tp - ieşirea doritã (impusã).

Se stabilesc următoarele relaţii:

output = f (W, inp);

c = err (tp, output) - o funcţie de eroare;

deci

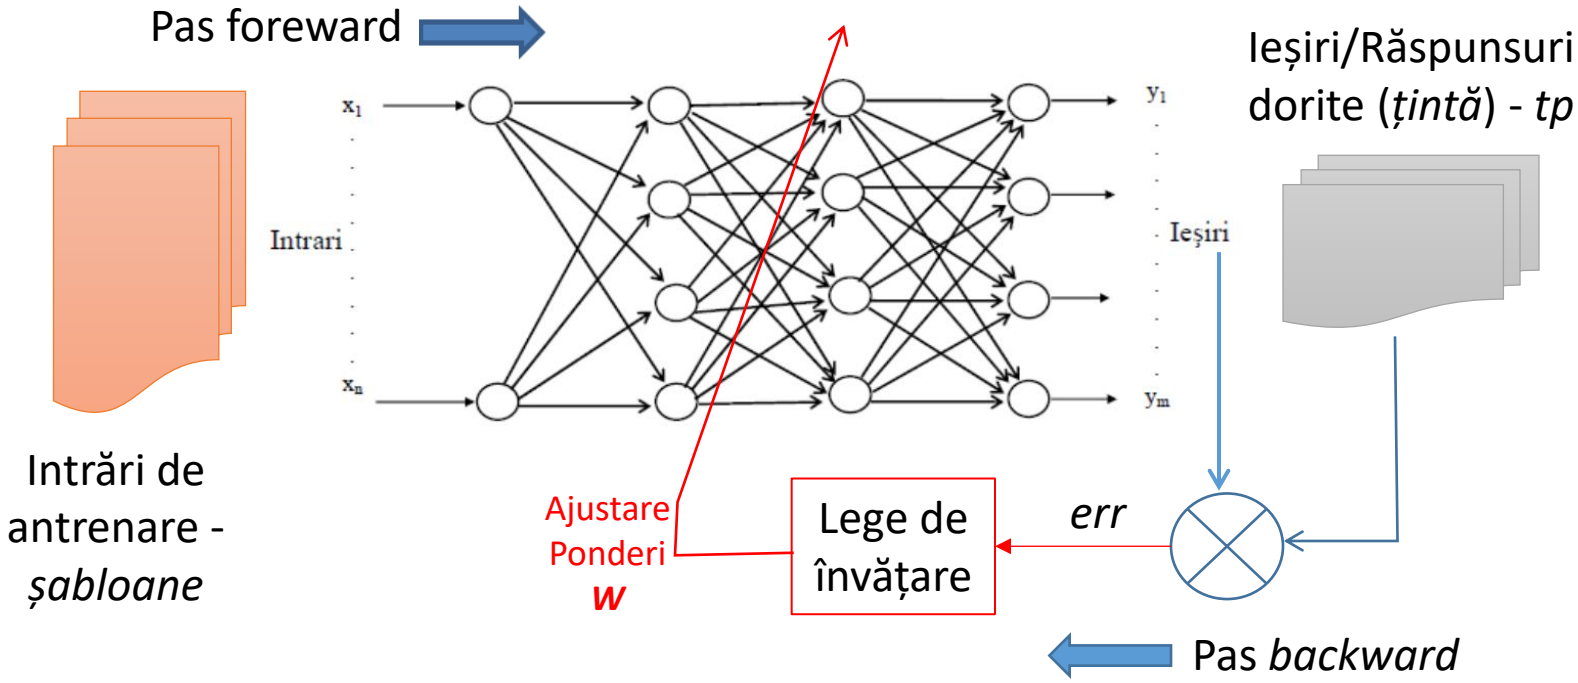
c = err (tp, f (W, inp))

Se pune condiţia ***c ≡ 0*** , adicã:

err (tp, f(W, inp)) = 0 (ecuaţie în W).

Învățarea supervizată (cont.)

- Ecuaţia ***err(tp, f(W, inp)) = 0*** este de fapt un *sistem de ecuaţii neliniare în w*, care nu se rezolvã exact ci cu ajutorul unor *metode iterative* (metoda gradientului, met. lui Newton combinatã cu cea a gradientului sau met. Fridman).
- Etapa în care se realizeaza *evaluarea întregului set de perechi de antrenament* de către reţea se numeşte *epocã de antrenament*.



Limite ale RNA feed-foreward

Probleme ce pot apare la antrenarea reţelelor feedforword folosind algoritmul de propagare înapoi.

Deşi este foarte răspândit în aplicaţii algoritmul backpropagation are următoarele probleme:

- Convergenţa nu are în general un grad corespunzător (numărul de iteraţii pentru determinarea soluţiei fiind mare), uneori metodele iterative *fiind divergente*;
- Paralizarea reţelei - în urma unui proces îndelungat de antrenament, ponderile reţelei pot să ajungă la valori foarte mari, ceea ce conduce la valori net ale neuronilor, de asemenea foarte mari. Valorile net astfel rezultate determincă valori *OUT=F(net)* aproape de asimptota orizontală, deci în zona cu derivată foarte mică (tinzând către zero) a funcţiei de activare.
- Minimul local

Algoritmul de propagare înapoi foloseşte metoda gradientului (gradient descent) pentru a ajusta ponderile astfel încât suprafaţa funcţiei de eroare este parcursă spre *minimul global*. În cazul problemelor mai complexe, *suprafaţa funcţiei de eroare este neregulată şi prezintă o mulţime de minime locale*. În acest caz se poate ca *reţeaua să se stabilizeze într-un astfel de minim local şi antrenarea eşuează.*

Limitele RNA feed-foreward (cont.)

- Problematica fundamentală constă în ***capacitatea de învățare limitată* a RNA**:

Practic, se manifestă **inabilitatea de a învăța (memora) noi forme fără a se altera cele învățate** deja,

Dilema *stabilitate-plasticitate*: *compromis de proiectare a RNA în ceea ce privește arhitectura rețelei, viteza de lucru* și *dimensiunea rețelei* astfel încât rețeaua să fie capabilă să recunoască vechile forme (să fie *stabilă*), dar să poată memora și noile forme (să prezinte *plasticitate*, să fie adaptivă)

Soluție pentru depășirea dilemei: RNA bazate pe *teoria rezonanței adaptive (ART) cu ajutorul* ***rețelei ART cu învățare nesupervizată***.

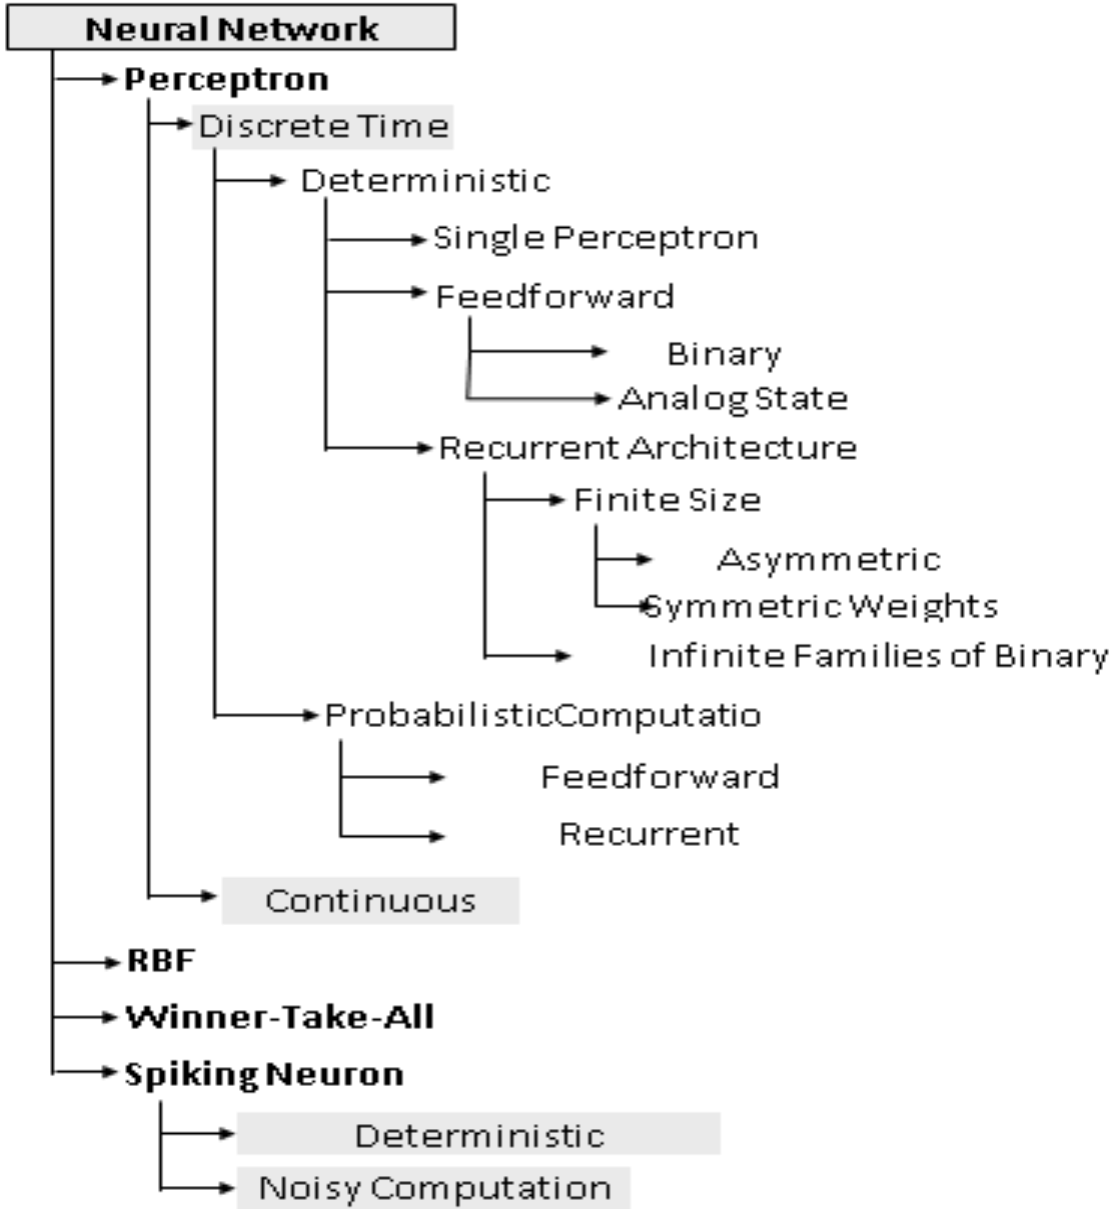
- **Overfitting (Supraînvățare)**

Este starea în care **rețeaua învață „prea bine" și memorează pe de rost datele de antrenament**, inclusiv zgomotul (erorile aleatorii) din ele. Rețeaua devine extrem de capabilă pe datele cunoscute, dar își pierde capacitatea de generalizare.

Cauza: Modelul este prea complex pentru un set de date prea mic (are prea mulți neuroni sau straturi), ori antrenarea a fost lăsată să ruleze mult prea multe epoci.

Simptom: Pe graficul de antrenare, eroarea pentru datele de test/validare începe să crească brusc, în timp ce eroarea pentru datele de antrenament continuă să scadă spre zero.

În general, **clasificarea RNA** depinde de *mai multe criterii*.
Multe arhitecturi de RNA s-au dezvoltat pe baza unor *tipuri particulare de neuroni* : de exemplu *RBF* – cu funcții de activare radiale, sau *spiking neuron* – un model mai fidel al neuronului biologic.



Concluzii

1) Modelele *conexioniste* permit implementarea unor funcții ale IA prin instrumente de tip **Rețea Neuronală Artificială (RNA**).

2) Neuronul artificial este un *procesor elementar* de semnale/date.

3) Perceptronul este o rețea *multistrat*, *total conectată*, de tip *feed-foreward*.

4) Învățarea/antrenarea RNA poate fi *supervizată* sau *nesupervizată*.

5) Principala problemă a RNA feed-foreward cu învățare supervizată este *dilema stabilitate-plasticitate*.

-*vezi și demo interactiv – Matlab (pâna la versiunile R2021): nnd*