Sisteme inteligente
#11

Tehnici de învățare/antrenare a rețelelor neuronale artificiale şi modul de prelucrare a datelor. Legi de învăţare a RNA. (2ore)

RNA modele ale IA pentru funcția de învățare

- **Învățarea** = *capacitate necesară dar nu suficientă* a unui sistem pentru a fi considerat **inteligent** (cu IA).
- Învățarea presupune abilitatea de a *clasifica* formele.
- O rețea neuronală artificială construiește (implementează) *funcții de separare* a unor mulțimi de obiecte pe baza unor *trăsături măsurabile* ale acestora.
- Învățarea rețelei se concretizează în *ponderile numerice (W)* ce caracterizează conexiunile dintre neuroni. Numărul legăturilor (ponderilor) reflectă *capacitatea de învățare* a rețelei.
- Învățarea RNA= instruire, antrenare (*learning*, *training*)

TEHNICI DE ÎNVĂȚARE

Supervizată

- Ca principiu este asimilată cu „mod de predare”, sau învățarea cu profesor (după modele).
- Necesită exemple (modele) de învățare preliminare (selectate) sub formă *date de instruire etichetate* (șabloane).

Nesupervizată

- Nu sunt necesare date de instruire *etichetate.*
- Sistemul învață prin *autoorganizarea intrărilor* curente în funcție de starea ieșirilor. Starea ieșirilor determină gruparea intrărilor (Self-Organizing Map – SOM)

Prin consolidare

Învățarea prin execuție:

- un *agent* face evaluarea acțiunii în mediul real de lucru, si elaboreaza o *recompensă (sau o penalizare)* și o transmite înapoi pentru a ajusta starea sistemului.
- Acțiunea de învățare *optimă* devine posibilă prin repetiție *fără date de antrenare etichetate* - (învățare consolidată).

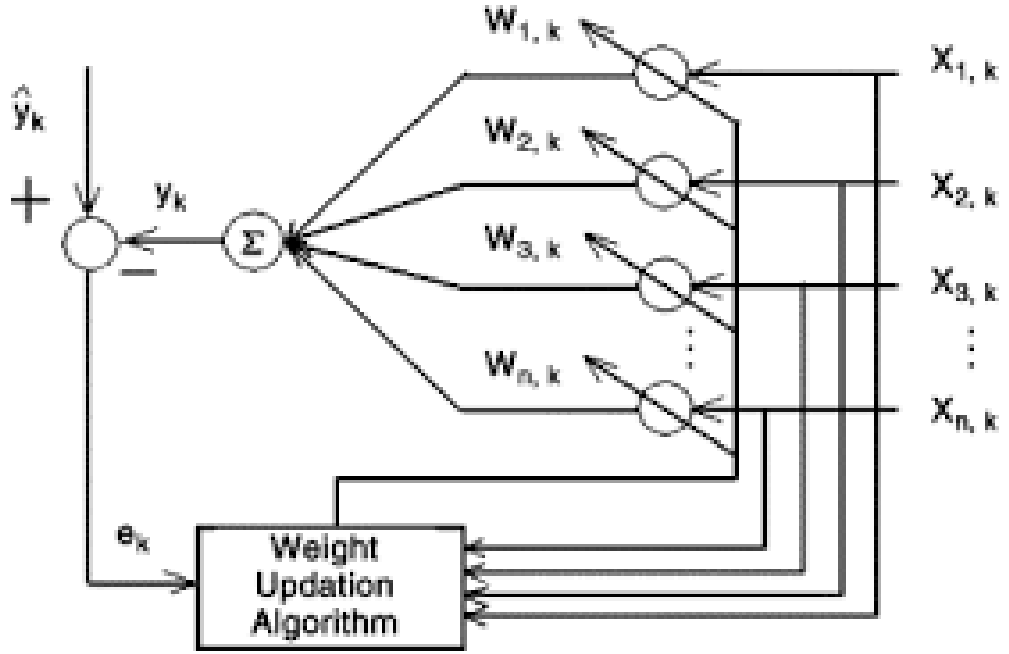
Învățarea supervizată

Principiul:

- Se bazează pe metoda *încercare şi eroare* care se aplică prin perechea de pași *foreward-backward*. Algoritmul de *propagare înapoi a semnalului de eroare* (backpropagation) este specific învățării supervizate.
- Această tehnică de antrenare (instruire) a RNA presupune existența datelor de antrenare organizate astfel: pentru fiecare vector de intrare câte un vector de ieşire reprezentând răspunsul dorit pentru intrarea dată. Împreună, cei doi vectori asociaţi formează o pereche de antrenament. Numărul de perechi de antrenament necesare depinde de tipul şi complexitatea problemei.

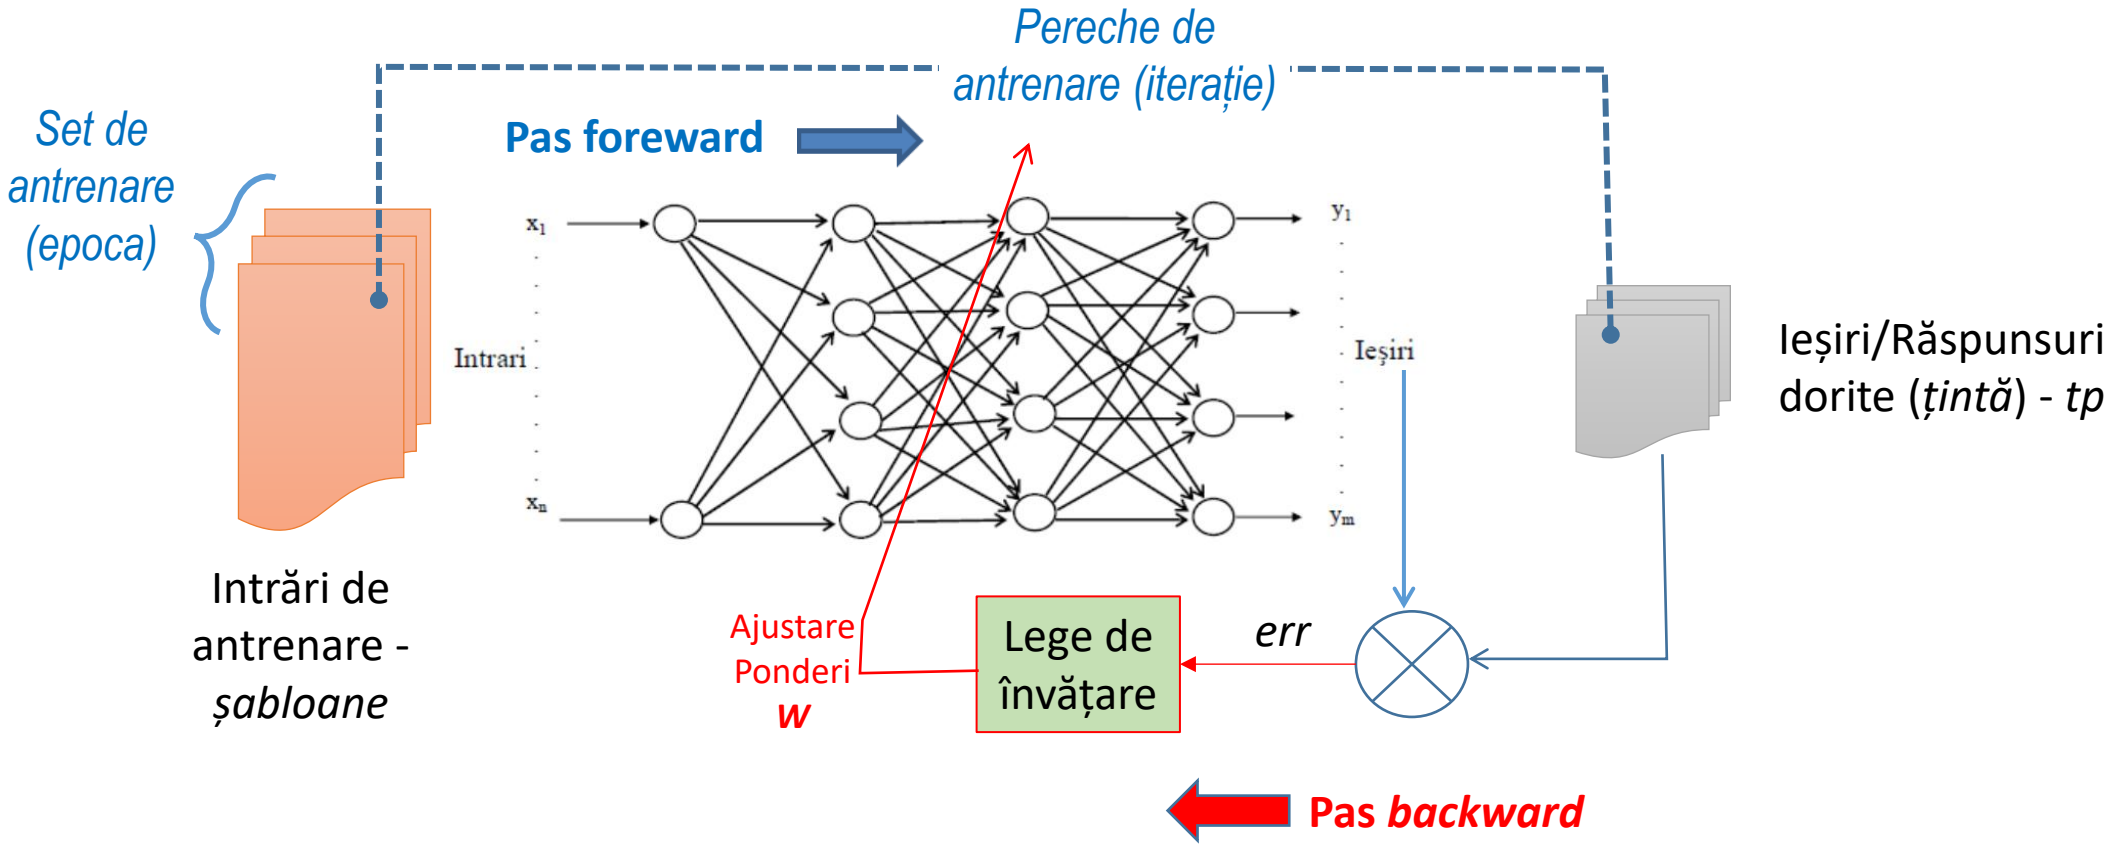
Neuronul ADALINE modelul de bază pentru învățarea supervizată

- **Modelul Ada**ptive **Li**near **Ne**uron (ADALINE) a stabilit principiul învățării supervizate pe baza adaptării ponderilor prin *backpropagation*.
- Regula de învățare originală: *Widrow-Hoff* (depinde de y_d, w_{ij} *și* x_i)



Învățarea supervizată (cont.)

Ecuaţia ***err(out_target, f(W, input)) = 0*** este de fapt un *sistem de ecuaţii neliniare în W*, care nu se rezolvă exact, ci cu ajutorul unor *metode iterative* (de exemplu: metoda gradientului, metoda lui Newton combinată cu cea a gradientului sau metoda Fridman). Metodele urmăresc găsirea minimului (absolut) al funcției de eroare *err.*



Procesul de antrenare (învățare supervizată)

- Procesul se derulează *iterativ* în cadrul unor *epoci de învățare pe baza celor doi pași ai învățării supervizate: foreward și backward*.
- *Iterație=parcurgerea pașilor foreward-backward pentru o (singură) pereche de antrenare șablon-ieșire țintă.*
- *Epocă de antrenare=parcurgerea câte unei iterații pentru fiecare pereche de antrenare.*

i. Pasul foreward: se prezintă o pereche de antrenare și se calculează *eroarea*.

ii. Pasul backward: se "*propagă eroarea înapoi*" process în care se ajustează ponderile prin legea de învățare.

iii. Se prezintă perechea de antrenare următoare și *se reia ciclul* pașilor *foreward-backward*.

iv. La *epuizarea șabloanelor de învățare se înregistrează o epocă de antrenare a rețelei*

v. Se continuă cu *epoci succesive de antrenare* până când *eroarea globală* atinge un *minim absolut impus* sau până se atinge o *limită stabilită* pentru *numărul maxim de epoci* de antrenare.

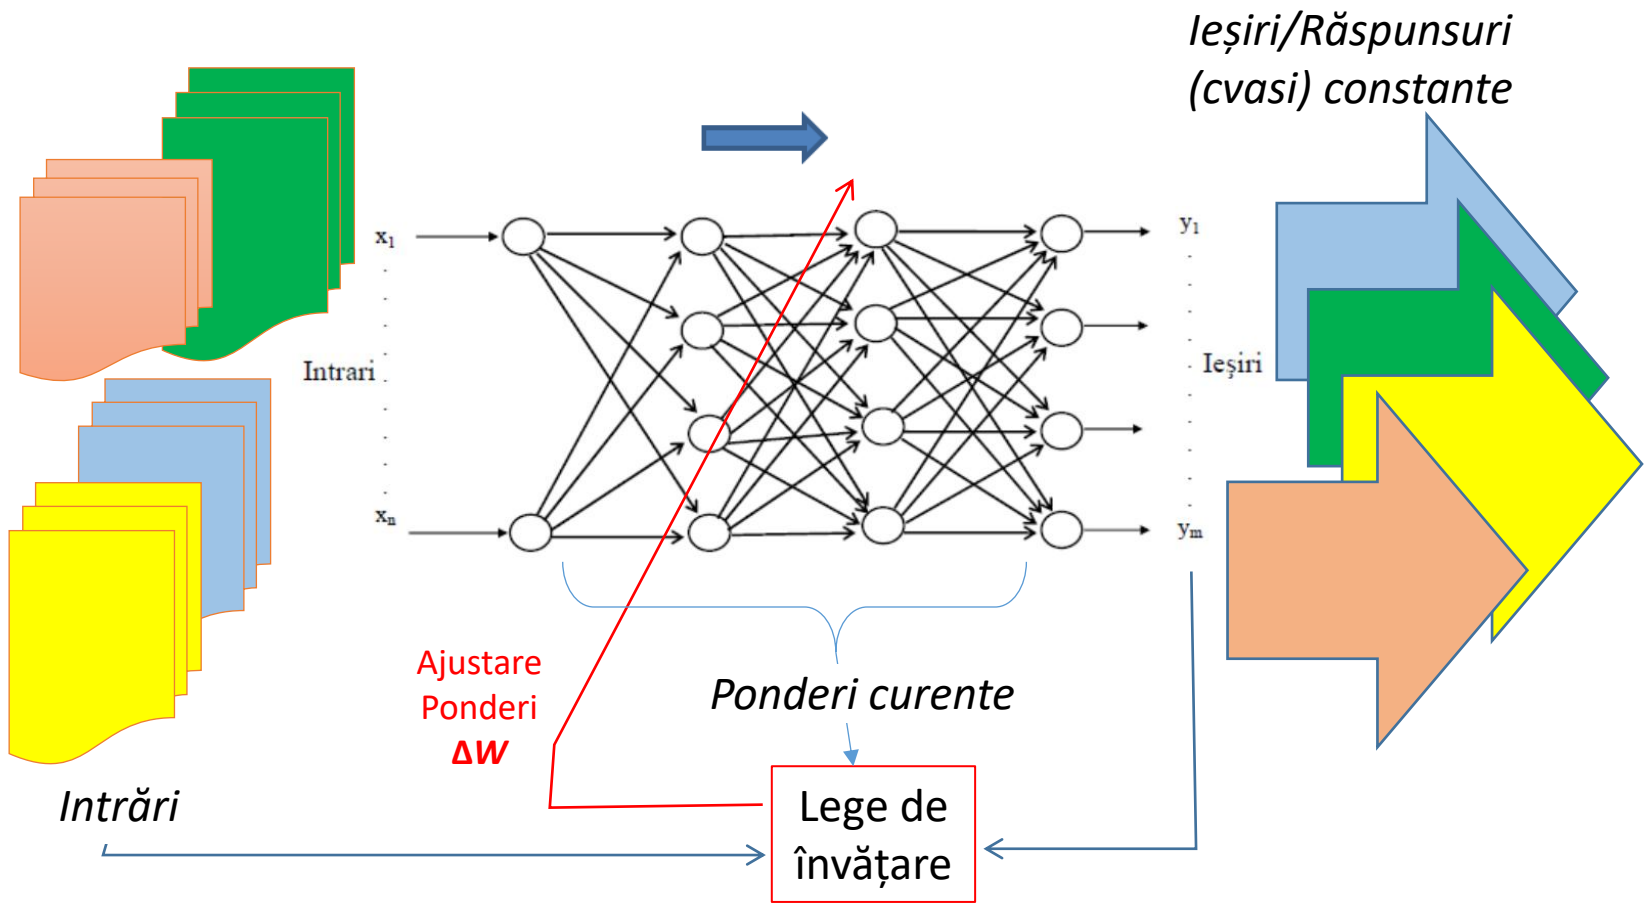
Învățarea nesupervizată

Principiul:

- **Nu necesită vectori de date de antrenament şi nici operaţii de compunere şi propagare înapoi a erorilor**, în procesul de determinarea a unui răspuns dorit.
- Setul de antrenament constă numai din vectori de intrare, care, pe parcurs sunt **grupaţi în clase** ce determină **aceleaşi ieşiri**.
- Aplicându-se unul din vectorii de intrare sau un vector **suficient de apropiat** de acesta (din aceeaşi clasă) reţeaua va produce aceeaşi ieşire.
- Trebuie menţionat că nu există nici o posibilitate de anticipare (înainte de antrenarea rețelei), a vectorului de ieşire asociat de reţea unei clase din setul vectorilor de intrare. *Rețeaua prelucrează continuu date din fluxul de informații curent* și *încearcă să se adapteze prin învățare să distingă posibile clase de date*. Tehnica învăţării nesupervizate se apropie mai mult de modul de învăţare natural specific sistemelor biologice.

Învățarea nesupervizată (cont.)

- Intrările sunt grupate prin *autoorganizare* în funcție de *comportamentul ieșirilor*.
- Autoorganizarea se face pe baza unor *măsuri statistice de similaritate a intrărilor*.
- În procesul de învățare ponderile se ajustează astfel încât gruparea de *clustere* de intrări să producă o ieșire cât mai constantă.
- Învățarea nesupervizată este privită ca un *proces de adaptare.*



Legi de învățare a RNA

Legea generală de învățare stabilește relația prin care sunt *ajustate* (modificate) ponderile conexiunilor pe timpul procesului de antrenare:

$$W_{ij}(t+1)=W_{ij}(t)+X_i(t)\cdot r\cdot c$$

Unde:

r- este un *semnal de învățare*, o funcție ce poate depinde de intrări, valorile curente ale ponderilor, ieșirea țintă, ieșirea curentă.

c- o *constantă de învățare* care semnifică *rata* învățării

Considerând învățarea ca un *proces continuu în timp*, atunci se poate scrie:

$$dW_{ij}(t)/dt = r \cdot c \cdot X_i(t)$$

<u>NOTĂ</u>: din punct de vedere matematic, procesul este continuu, dar în modelele numerice pe calculator procesele se desfășoară la momente discrete de timp, în mod iterativ (t0=t, t+1, t+2, ... t+k,..., t+n). Prin urmare, ponderile sunt ajustate incremental cu valori finite:

$$\Delta W_{ij} = W_{ij}(t+1) - W_{ij}(t)$$

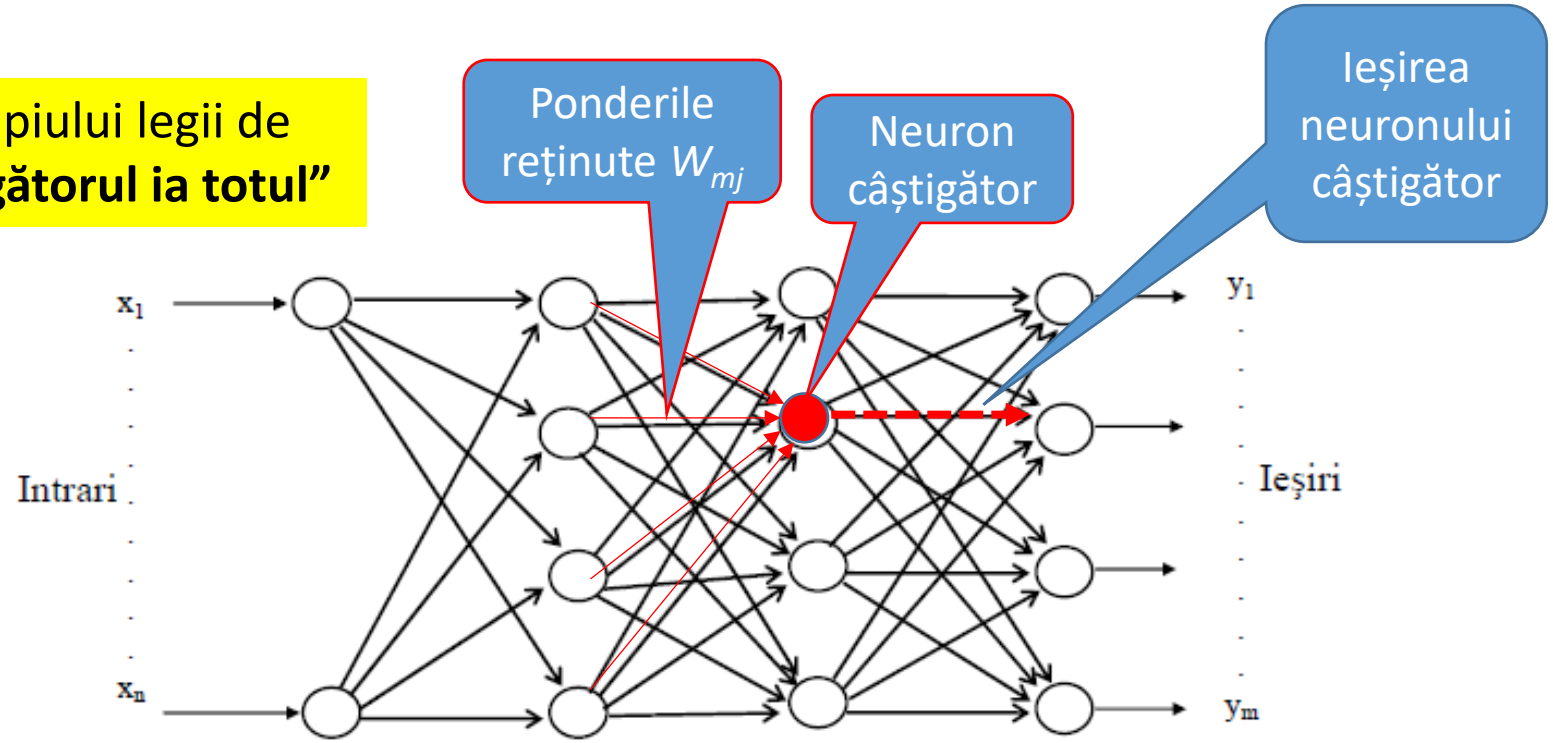
Legi de învățare particulare

Legea de învățare	Semnalul (funcția) de învățare	Incrementul de ajustarea a ponderilor
Hebb (1949) - Tipică pentru învățarea nesupervizată (exclusiv feed-foreward) - Inițializarea ponderilor se face cu valori aleatoare mici (în jurul lui 0) - Descriere: procesul de transmitere a semnalelor între doi neuroni I și J se accelerează pe măsură ce I excită tot mai persistent sau repetat pe J. (Proces similar avalanșei)	$r = f(W_{ij}, X_i)$ *NU depinde de ieșiri țintă!*	$\Delta W_{ij} = c \cdot f(W_{ij}, X_i) \cdot X_i =$ $= c \cdot O_i \cdot X_i$
Perceptron (1958) - Semnalul de învățare este generat de diferența dintre răspunsul curent (O_i) *și cel dorit (țintă* d_i*) al neuronului considerat* - *Exclusiv pentru învățarea supervizată*	$r = d_i - O_i$	$\Delta W_{ij} = c \cdot [d_i - O_i] \cdot X_i$

Legea de învățare	Semnalul (funcția) de învățare	Incrementul de ajustarea a ponderilor
Widrow-Hoff (1962) - Aplicabilă pentru învățarea supervizată - Ponderile se pot inițializa cu orice valoare	$r= d_i - W_{ij} X_i$	$\Delta W_{ij} =c(d_i - W_{ij} X_i)\cdot X_i$
Delta (1986) - Aplicabilă doar pentru învățarea supervizată - Impune utilizarea funcțiilor de activare continue (derivabilitate)	$r= [d_i - f(W_{ij}, X_i)]\cdot f'(W_i, X_i)$	$\Delta W_{ij} = c(d_i - O_i)\cdot f'(W_i, X_i)\cdot X_i$
Corelare - Se bazează pe produsul dintre ieșirea dorită și intrare	$r= d_i$	$\Delta W_{ij} = c\, d_i\, X_i$
“Câștigătorul ia totul” - Diferă semnificativ de alte legi de învățare prin faptul că este de tip competitiv, - Se aplică la învățarea nesupervizată, - Principiu: un singur neuron dintr-un anumit strat oferă răspunsul maxim pentru intrarea curentă X – acest neuron se declară “neuron câștigător”	*Se reține vectorul ponderilor legăturilor către neuronul câștigător* $W_m =[W_{m1}, W_{m2},\ldots, W_{mn}]$	$\Delta W_{mj} = \alpha(X_j - W_{mj})$ $J=1,2,\ldots,n$ $\alpha>0$ constantă *Se ajustează doar ponderile către neuronul câștigător*

Legea de învățare	Semnalul (funcția) de învățare	Incrementul de ajustarea a ponderilor
“Outstar” -lege tipică pentru caracteristici repetitive ale relației intrare-ieșire	-	$\Delta W_{mj} = \beta(d_i - W_{ij})$

Ilustrarea principiului legii de învățare **“Câștigătorul ia totul”**



Exemple vizuale demonstrative, interactive

- Demo Matlab *(până la versiunile R2021)*, toolbox **nnd** *Chapters 10 -v12*
- *Pentru versiunile ulterioare aplicațiile demonstrative pot fi găsite ca fișiere Live Script (.mlx) pe sie-ul Mathworks la* **Fundamentals of Neural Networks** pe MATLAB File Exchange.