Sisteme inteligente
#13

Sisteme inteligente bioinspirate. Modelarea sistemelor evolutive. Algoritmi genetici cu aplicaţii în probleme de de optimizare. (2ore)

Sisteme inteligente **bioinspirate**

- Sunt **sisteme artificiale** care se bazează pe modele de comportament inspirate din lumea vie.
- Paradigma sistemelor bioinspirate intersectează domeniul inteligenței artificiale formând un nou domeniu de studiu cunoscut sub denumirea de “Artificial Life”.
- Modele bioinspirate cu aplicații în sisteme inteligente și controlul sistemelor:
  - Algoritmi evolutivi – Algoritmi genetici,
  - Particle Swarm (Roiuri de particule) – Particle Swarm Optimization (PSO)
  - Sisteme multiagent complexe – Agenți inteligenți

Modelarea sistemelor evolutive

- În inteligența artificială, *algoritmii evolutivi* (AEv) în general și în particular prin *algoritmii genetici* (AG) au un rol important în problemele de optimizare.
- Problema de optimizat poate avea ca obiectiv decizia sau proiectul unui sistem.
- Algoritmii evolutivi sunt *metode de căutare stocastice* (mod aleator, întâmplător), care imită metafora evoluției naturale (biologice).
- AEv operează pe o populație de 'indivizi' privite ca soluții potențiale ale unei probleme aplicând principiul *supraviețuirii* celui mai bun individ și a perpetuării sale prin capacitatea lui de a produce *urmași* – adică *aproximații din ce în ce mai bune ale soluției (de optimizare)* a problemei.
- Urmașii, ca soluții parțiale ale problemei, evoluează prin *operatori genetici*, creând la rândul lor noi aproximații.
- *"Supraviețuirea"* celor mai buni indivizi (persistența soluțiilor cele mai bune) se face prin imitarea procesului de *selecție naturală* testând *adaptabilitatea* lor *(fittness)* la condițiile problemei.
- AEv sunt *procese paralele* deoarece operează în masă, asupra întregii populații .

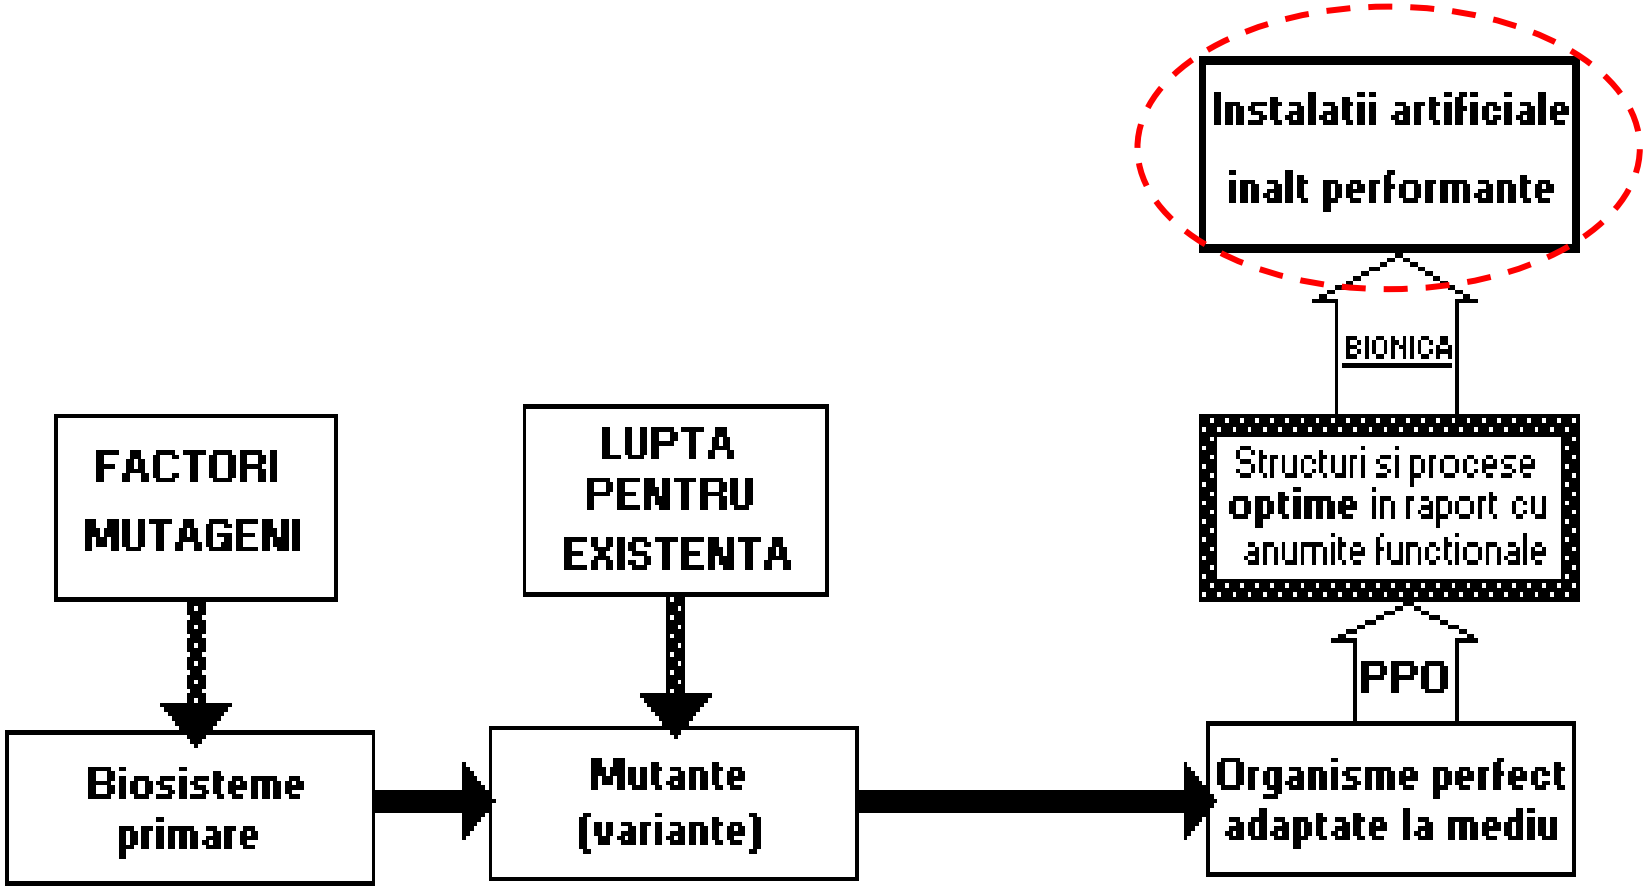
Algoritmii genetici (J.Holland, anii ‘70)

- AG reprezintă o tehnică de implementare a AEv bazată pe operatorii genetici principali: *mutația* și *încrucișarea*.
- AG se aplică în probleme de optimizare cu complexitate mare *fără a necesita* modele matematice cu *funcții obiectiv* continue și derivabile sau unimodale (cu un singur extremum).
- Există două condiții necesare și suficiente pentru aplicabilitatea AG la o problemă de optimizare:

  1) Sistemul de optimizat să fie descris de un *set de parametri* – *variabile de decizie sau de proiectare*.

  2) Să existe cel puțin o funcție pentru evaluarea calității sistemului în raport cu obiective bine determinate – *funcții scop* sau *obiectiv*.

Principiul proiectului optim



Forma generală a problemei de optimizare cu un singur obiectiv

- Fie un sistem descris de un vector de *p* parametrii, care sunt *variabile de proiectare* sau de *decizie*: x1, x2, ..., xp. Acestea pot reprezenta mărimi fizice concrete (durate de timp, caracteristici dimensionale, greutate, etc.) și/sau cantități de elemente, indicatori de formă, coeficienți de calitate, etc.
- OPTIMIZARE înseamnă căutarea și găsirea *minimului* unei **funcții obiectiv** definită sub forma:

$$\phi = f(x1, x2, \ldots, xp)$$

- Unde Φ poate fi unul dintre parametrii problemei ales ca și *criteriu de optimizare* (de pildă durata de timp, greutatea sau numărul de elemente), ca funcție de anumite variabile ale problemei.

Optimizarea în condiții de restricții

- În general problemele reale au ***restricții*** și de aceea soluțiilor posibile trebuie să li se impună un set de *q* restricții:

$$\begin{cases} g1(x1,x2,\ldots,xp)\le 0 \\ g2(x1,x2,\ldots,xp)\le 0 \\ \ldots\ldots\ldots\ldots\ldots\ldots\ldots \\ gq(x1,x2,\ldots,xp)\le 0 \end{cases}$$

- Aceste restricții pot fi relații (condiții) de verificare a sistemului la diferite sarcini, pot fi restricții de timp sau de cost, ori de gabarit.

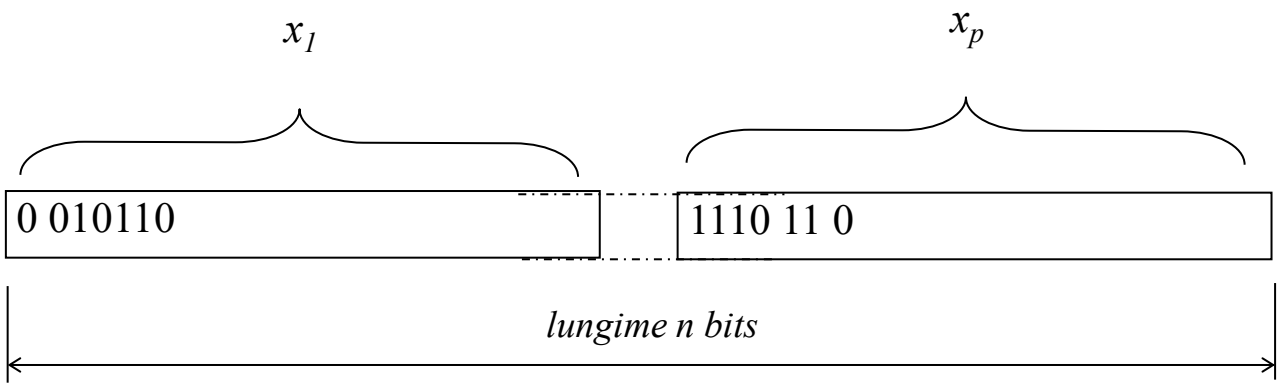
Principiul de lucru al **algoritmilor genetici**

Analogia de termeni utilizată

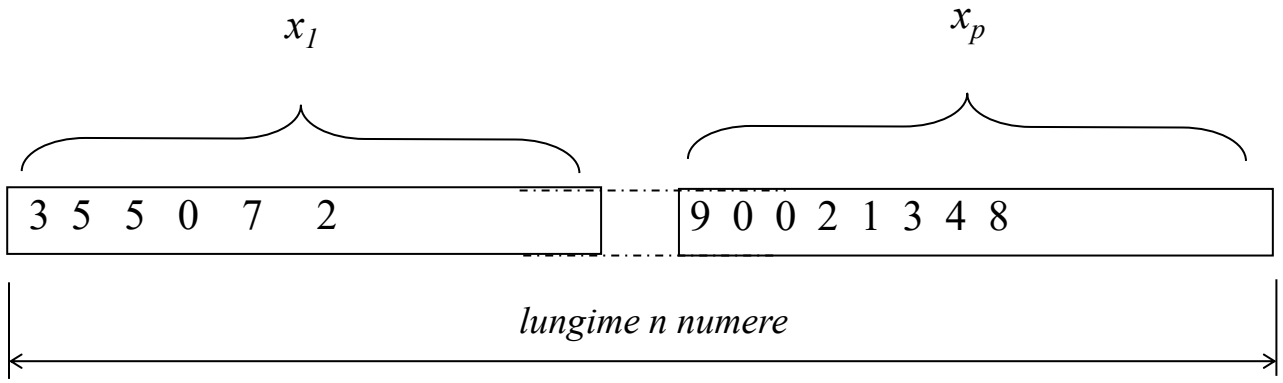
Sisteme biologice	Sisteme artificiale	Notație
Populație	Mulțime de soluții	N
Individ (membru)	Soluție particulară	s_j $j= 1,..,N$
Cromozom	Codul soluției	c_j
Genotip	Soluția codificată	-
Fenotip	Concretizarea codului în caracteristici ale soluției	-
Genă	Element de codificare	g_{ij} $i=1,..,n$
Alelă	Valoarea unei gene (binară sau cu numere reale – în virgulă mobilă)	0 ,1 sau 0...9
Adaptabilitate	Valoarea soluției calculată cu o *funcție de fitness*	F
Selecție naturală	Strategie elitistă (mod de selecție a soluțiilor)	-
Mutație	Probabilitate de alterarea/schimbarea valorii unei gene în codul soluției	Pm
Încrucișare	Probabilitate de combinare între două soluții (reproducere)	Pc
Părinți	Soluții selectate aleator pentru încrucișare	-
Urmași	Soluții rezultate în urma încrucișării	-
Generație	Etapă de evoluție/iterație reprezentând mulțimea de soluții după reproducere	

Codificarea soluțiilor

Cromozom codificat binar



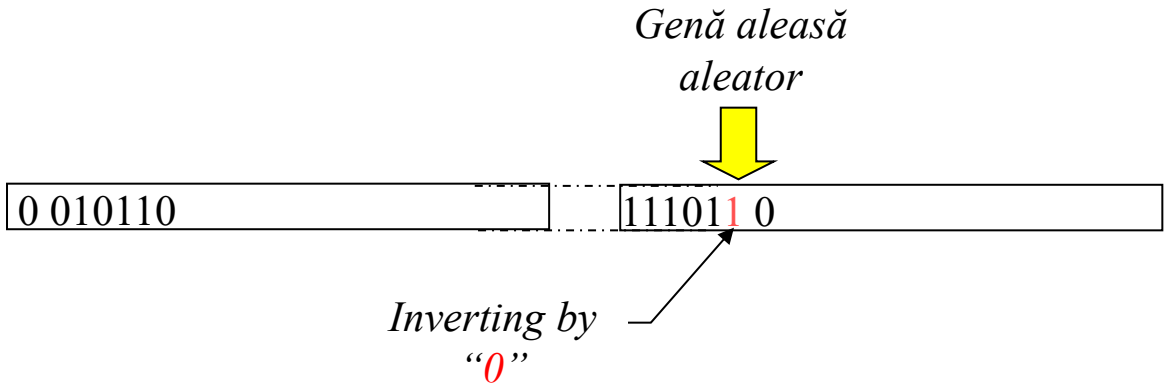
Cromozom codificat cu numere reale (real-coded)



Operații/operatori genetici

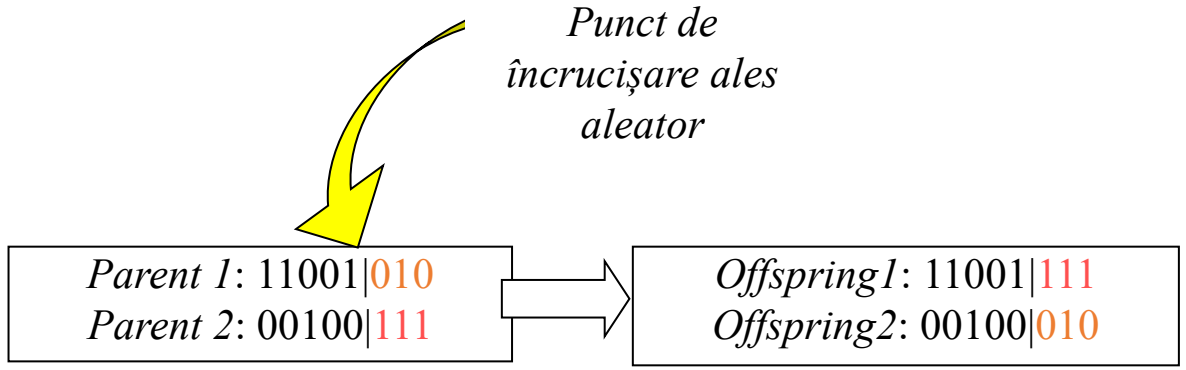
Probabilitatea de mutație *Pm* se alege cca 1% (0,01).

Mecanismul mutației



Probabilitatea de încrucișare *Pc* se alege până în 30% (0,3)

Mecanism posibil de încrucișare



Echivalența genotip-fenotip sau cod-valoare a soluției pentru codificarea binară

- Pentru codificarea binară a unei soluții (individ) pe *n* biți *<b1,b2,…,bn>* se face conversia în valoare reală cu relația:

$$V=2^n$$

- Această relație de calcul este utilă și pentru stabilirea numărului de biți (lungimea codului) pentru orice parametru real al problemei, astfel:

$$n=\log_2 V$$

Pașii algoritmului

1. Se inițializează populația de soluții (aleator)
2. Se calculează *funcția de fitness* (obiectiv)
3. Se *ierarhizează* mulțimea de soluții
4. Se aplică mecanismul de *selecție*
5. Se aplică *operatorii genetici* pe întreaga populație
6. Se reia de la pasul 2

- Convergența procesului*!*

Selecția soluțiilor

- **Selecția** este procesul (aleator) prin care *se aleg din populație acei indivizi* care vor participa la *reproducere prin încrucișare* și vor da naștere la urmași.
- Selecția se face în doi pași:

1) Se evaluează adaptabilitatea (fitness) pentru fiecare soluție,

2) Se efectuează selecția propriuzisă pe baza valorii funcției fitness.

Funcția fitness

- Caracterizează fiecare soluție s_j și este o măsură a *adaptabilității* fiecărei soluții individuale (potrivirea, adică 'fitness-ul' acesteia) în raport cu o valoare optimă.
- Este reprezentată prin *funcția obiectiv* care trebuie optimizată (minimizată sau maximizată, în funcție de problemă) în spațiul parametrilor:

$$F(s_j)=f_j(x1,x2,...,xp)$$

Metode de evaluare a fitness-ului soluțiilor

În procesul de selecție, adaptabilitatea unei soluții poate fi judecată în diferite feluri, prin modul de calcul al *funcției fitness*, astfel:

i) dacă se stabilește (se cunoaște) o valoare optimă de referință a funcției obiectiv (f_c^*) atunci funcția fitness este o *distanță*:

$$F_j = \left| f_c^* - f_j \right|, \quad j = 1,2,..., N$$

ii) ca *valoare relativă*:

$$F_j = \frac{f_j}{\sum_{j=1}^{N} f_j}$$

iii) Prin *scalare liniară* (adaptabilitate scalată):

$$(F_j)_{scalată} = a \cdot f_j + b$$

- Unde coeficienții a și b se calculează în funcție de valoarea minimă, medie și maximă a funcție fitness la nivelul populației.

iii) Prin *atribuire exponențială* (Boltzman):

$$F_j = e^{\pm \frac{f_j}{T}}$$

Unde T este un parametru (de regulă variabil în timp, de la o generație la alta), semnul ‘ + ’ este folosit pentru probleme de maximizare, iar ‘ – ‘ pentru cele de minimizare.

Notă. Cu rezultate bune, parametrul T poate fi considerat *rangul individului* din populație (poziția acelei soluții) care are valoarea funcției fitness cea mai apropiată de *media valorilor funcției fitness* pentru întreaga populație curentă.

Selecția propriuzisă – tehnici posibile

a) Se *ierarhizează* soluțiile în funcție de adaptabilitatea lor evaluată cu funcția fitness

b) Se aplică *mecanismul elitist* prin care se asigură perpetuarea soluțiilor bune de la o generație la alta – pe principiul *înlocuii soluției cea mai slabă cu cea mai buna*. Acesta este un mecanism artificial prin care se conservă volumul populației (numărul de indivizi N).

c) Se aplică diverse *metode de selecție a lotului soluțiilor care se vor supune reproducerii* (prin operația de încrucișare). Cei mai populari algoritmi sunt:

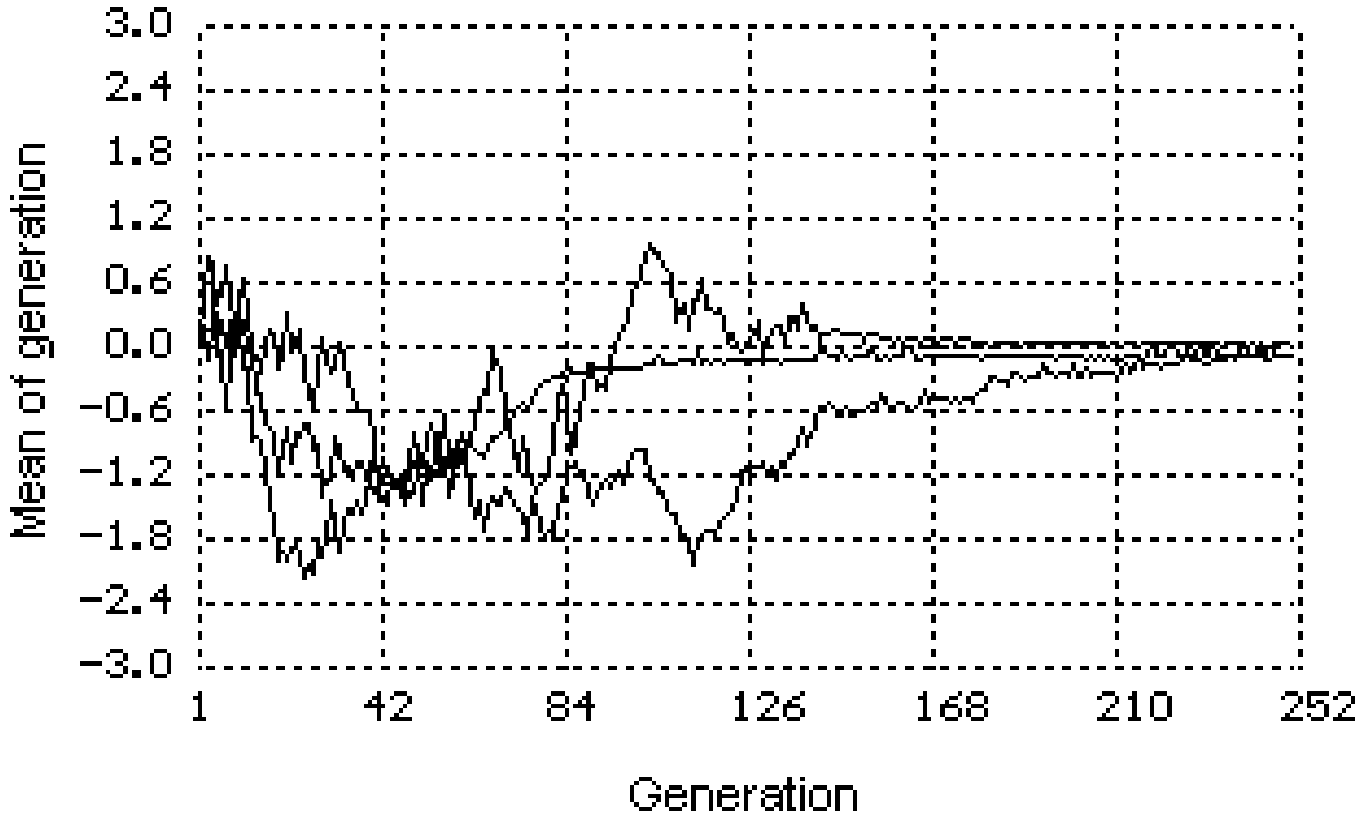
- Metoda ruletei (metoda de eșantionare stocastica de tip Monte-Carlo): probabilitatea de selecție este direct proporțională cu adaptabilitatea relativă a soluțiilor.
- Prin trunchiere – din mulțimea de soluții ierarhizate după valoarea funcției de fitness de stabilește un prag procentual până la care se selectează volumul supus reproducerii (cel mult 50% și nu mai mic de 10%).
- Metoda 'turnir' (de tip campionat) – este o metodă competitivă în care se fac *K* selecții aleatoare succesive de grupuri de *Nc* soluții din care, de fiecare dată se alege cea mai bună soluție pentru lotul de reproducere. Selecțiile (campionatele) continuă 1,...,K până când este atins numărul maxim de indivizi ai lotului de reproducere

Exemplificare prin simulare: Aplicarea funcției obiectiv și analiza convergenței procesului

Funcția fitness asimilată cu distanța

$$F_k = \left| i_k^c - i_k^* \right|, \quad k = 1,2,\ldots, n$$

Exemple de convergență a ***mediei*** funcției fitness



Concluzii

1) Algoritmii genetici (AG) *modelează procesul de evoluție* naturală prin *simularea* selecției și aplicarea probabilistă a operatorilor de încrucișare și mutație asupra unei populații (mulțimi) de indivizi (soluții).
2) Există o echivalență a termenilor din genetică cu termeni specifici sistemelor tehnice – formalizate matematic.
3) Procesul modelat conduce la evoluția populației, cu soluții din ce în ce mai bune în raport cu funcția obiectiv (fitness), astfel încât media întregii populații converge pe parcursul mai multor generații/iterații către obiectiv (minimul sau maximul criteriului de optimizare).